Отчёт по практическому занятию 2

Прогнозирование оттока клиентов телеком оператора

В работе построена модель для прогноза оттока клиентов оператора связи. Использован датасет Telco Customer Churn от IBM: 7043 клиента и 21 исходный столбец. Основная модель CatBoost обучена внутри Pipeline вместе с предобработкой признаков. На тестовой выборке она получила ROC-AUC 0.8466.

Источник данных:
https://raw.githubusercontent.com/plotly/datasets/master/telco-customer-churn-by-IBM.csv

1 Данные и подготовка

Целевая переменная - Churn: 1 означает, что клиент ушёл, 0 - что остался. Доля ушедших клиентов составила 26.5%, поэтому классы несбалансированы. В столбце TotalCharges было 11 пустых значений; после приведения к числу они заполнены нулями. Идентификатор customerID исключён из признаков, так как он уникален для каждого клиента.

Данные разделены на обучающую и тестовую части в пропорции 80/20 с параметром stratify=y. Так в обеих выборках сохранилась доля оттока около 26.5%. В качестве численных признаков использованы SeniorCitizen, tenure, MonthlyCharges и TotalCharges; остальные 15 признаков являются категориальными.

2 Модель и кросс валидация

Для численных признаков в ColumnTransformer использован StandardScaler, для категориальных - OneHotEncoder с handle_unknown=ignore. Далее ColumnTransformer и CatBoostClassifier объединены в Pipeline. Такая схема исключает утечку данных: преобразования обучаются только на train-части каждого фолда.

Подбор параметров выполнен через GridSearchCV с трёхкратной стратифицированной кросс-валидацией и метрикой ROC-AUC. Проверялись depth = 4 и 6, а также learning_rate = 0.05 и 0.1. Лучший вариант: depth = 4, learning_rate = 0.05. Средний ROC-AUC на кросс-валидации равен 0.8496.

3 Результат CatBoost на тестовой выборке

Метрика	Значение
Accuracy	0.81
ROC-AUC	0.8466
F1 для класса Ушёл	0.5857
Recall для класса Ушёл	0.5160
Precision для класса Ушёл	0.68

ROC-AUC 0.8466 показывает хорошее ранжирование риска. При пороге 0.5 CatBoost находит 51.6% ушедших клиентов; для удержания клиентов важен высокий Recall.

4 Важность признаков

Самыми важными признаками стали помесячный договор Contract Month-to-month, срок обслуживания tenure, ежемесячная плата MonthlyCharges, договор на два года, оптоволоконный интернет и суммарные платежи. Это согласуется с интуицией: новые клиенты с помесячным договором и высокой платой чаще уходят.

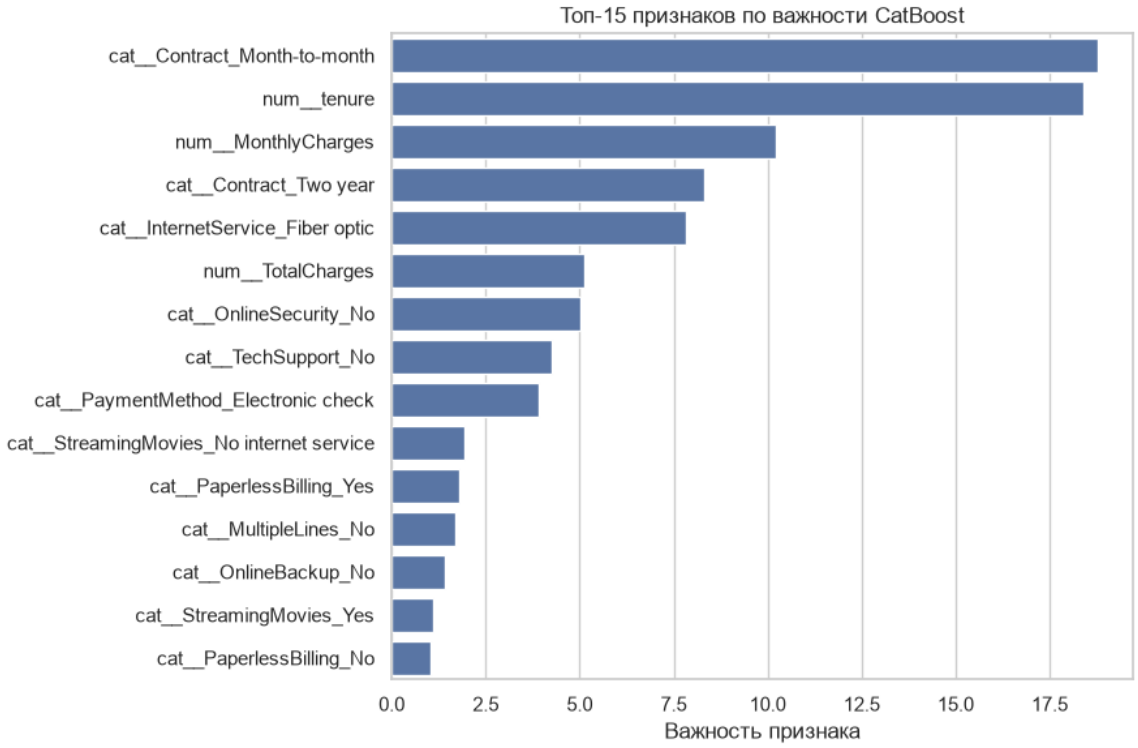


Рисунок 1 - Топ 15 признаков по важности CatBoost

5 Сравнение моделей

Модель	ROC-AUC	F1 класс 1	Recall класс 1
Logistic Regression	0.8421	0.6040	0.5588
Random Forest	0.8419	0.5797	0.5107
CatBoost	0.8466	0.5857	0.5160

По ROC-AUC лидирует CatBoost, хотя разница с Logistic Regression и Random Forest небольшая. По F1 класса Ушёл лучший результат у Logistic Regression. Поэтому CatBoost удобнее использовать для ранжирования риска, а выбор итоговой модели зависит от цели: максимальный ROC-AUC или более высокий F1 при фиксированном пороге.

6 Влияние SMOTE на Recall

Вариант	ROC-AUC	F1 класс 1	Recall класс 1
CatBoost без SMOTE	0.8466	0.5857	0.5160
CatBoost с SMOTE	0.8416	0.6284	0.7166

SMOTE применён только к тренировочной выборке внутри imbalanced-learn Pipeline. Recall вырос с 0.5160 до 0.7166, то есть на 0.2005. Модель стала находить больше клиентов, которые действительно уйдут. При этом ROC-AUC немного снизился, а часть оставшихся клиентов стала ошибочно попадать в группу риска. Если важнее не пропустить уходящих клиентов, вариант со SMOTE предпочтительнее.

7 Вывод

Построен полный Pipeline: предобработка через ColumnTransformer и CatBoostClassifier. Качество модели проверено с помощью GridSearchCV, classification report и ROC-AUC. CatBoost показал наибольший ROC-AUC среди трёх моделей, а SMOTE заметно увеличил Recall класса Ушёл. Для задачи удержания клиентов целесообразно рассмотреть вариант CatBoost со SMOTE, если стоимость пропуска оттока выше стоимости лишнего предложения клиенту.